

## 2. Exaktní a heuristická řešení konstruktivního problému batohu

Matej Šutý  
NI-KOP 2021  
Praha

<b>Popis implementovaných metod</b>	<b>2</b>
<b>Branch and bound:</b>	<b>2</b>
<b>Dekompozícia podľa ceny:</b>	<b>2</b>
<b>Greedy a redukovaný greedy algoritmus:</b>	<b>3</b>
Greedy algoritmus:	3
Redukovaný greedy algoritmus:	3
<b>FPTAS, Fully Polynomial Time Approximation Scheme:</b>	<b>4</b>
<b>Srovnání výpočetních časů metody větví a hranic, dynamického programování a heuristiky</b>	<b>5</b>
<b>Porovnání relativních chyb (průměrných a maximálních) obou heuristik.</b>	<b>7</b>
Absolutní chyba	8
<b>FPTAS: závislost chyby a výpočetního času algoritmu na zvolené přesnosti zobrazení</b>	<b>9</b>
Závislost chyby a výpočetového času:	10
Porovnání maximální chyby s teoretickou očekávanou chybou:	11
<b>Zhodnocení naměřených výsledků</b>	<b>13</b>
Odpovídají obě závislosti (kvality a času) předpokladům?	13
Je některá heuristická metoda systematicky lepší (tzv. dominance) v některém kritériu?	13
Jak se liší obtížnost jednotlivých sad z hlediska jednotlivých metod?	14
Jaká je závislost maximální chyby ( $\epsilon$ ) a času FPTAS algoritmu na zvolené přesnosti?	
Odpovídá předpokladům?	16

# Popis implementovaných metod

## Branch and bound:

Popísané v predchádzajúcom reporte, vrátane konštruktívnej verzie, na mojom fakultom [gitlabu](#).

V krátkosti:

Algoritmus vytvára binárny strom, kde v úrovni  $d_i$  pridá/nepridá predmet  $i$  do batohu. V každom liste ukladá hornú hranicu hodnoty batohu a súčasnú hodnotu. Ak niektorý list má hornú hranicu nižšiu ako súčasná hodnota iného listu, znamená to, že podstrom tohto listu určite nebude mať vyššiu hodnotu ako sme doteraz našli a preto sa tento list zatvorí a nepokračuje v ňom expanzia. Tento algoritmus je systematický a vždy prináša optimálne riešenie. Jeho zložitosť môže byť rovnako veľká ako zložitosť hrubej sily  $O(2^n)$ .

## Dekompozícia podľa ceny:

1. Nájsť maximálnu cenu  $c_i$  predmetu, ktorý **môže** byť v batohu ( $w_i \leq M$ ).
2. Vytvoriť tabuľku s rozmermi (počet predmetov + 1) x  $c_i$
3. Vyplniť tabuľku a vypíňať dopredným spôsobom
  - a.  $W(0,0) = 0$   
 $W(0,c) = \infty$  pro všechna  $c > 0$   
 $W(i+1, c) = \min(W(i, c), W(i, c-c_{i+1})+w_{i+1})$  pro všechna  $i > 0$ . \*
4. Nájsť najvyššiu hodnotu batohu
  - a. Výsledné řešení je určeno polem v posledním sloupci, které obsahuje váhu menší než  $M$  a má maximální index. Jestliže pole  $(n-1, c)$  obsahuje váhu stejnou jako pole  $(n, c)$ , pak  $n$ -tá věc není součástí optimálního řešení. Takto se dá rekonstruovat vektor  $X$  z tabulky. \*

\* prevzaté z cvičenia NI-KOP

Dekompozícia vždy nájde optimálne riešenie (môže byť nulové). Algoritmus je pseudopolynomiálny so zložitosťou  $O(n^2 c_{max})$ . Zložitosť závisí na maximálnej cene predmetu.

## Greedy a redukovaný greedy algoritmus:

### Greedy algoritmus:

Hladový algoritmus vyberá predmety podľa najvyššieho pomeru *cena/váha* až kým pridanie ďalšie predmety neprekročí kapacitu batohu.

Relatívna kvalita tohto algoritmu je ľubovoľne veľká ako vidno na ukážke prevzatej z cvičenia NI-KOP:

### Konstrukce příkladu selhání

- položíme  $M = kn$ ,  $k > 0$  libovolné
- položíme  $v_1 = v_2 = \dots = v_{n-1} = k$  a  $v_n = M$ .
- položíme  $c_1 = c_2 = \dots = c_{n-1} = k$  a  $c_n = M-1$ .

Heuristika vezme nejprve věci 1 ...  $n-1$ , protože mají poměr *cena/váha* rovný 1, zatímco  $n$ -tá věc má poměr *cena/váha*  $(M-1)/M$ . Dále,  $n$ -tá věc se do batohu již nevejde. Dosažená cena je proto  $n-1$ . Optimální řešení je pouze  $n$ -tá věc. Relativní kvalita je tedy

$$\frac{M-1}{n-1} > \frac{M}{n} = k$$

### Redukovaný greedy algoritmus:

Algoritmus vyberie najdrahší predmet, ktorý sa vojde do batohu a jeho cenu porovná s cenou batohu, ktorý vyrátal pomocou bežného greedy algoritmu a vyberie lepšie riešenie.

## FPTAS, Fully Polynomial Time Approximation Scheme:

Knapsack, ktorý je riešiteľný algoritmom s  $O(n^2 c_{max})$ , môžeme riešiť aproximačným algoritmom, pre ktorý výpočtová zložitosť závisí na požadovanej relatívnej chybe.

Hlavná myšlienka aproximácie spočíva v znížení presnosti cien predmetov, ktoré sa snažíme vložiť do batohu. Možné spôsoby sú :

a) odstrániť posledných  $b$  bitov v cene každého predmetu.

Zložitosť bude  $O(n^2 \cdot \frac{C_{max}}{2^b})$ , v závislosti na požadovanej chybe  $\epsilon$  volíme

počet bitov  $b = \text{floor}(\log \frac{\epsilon \cdot C_{max}}{n})$ ,  $n$  je počet všetkých predmetov.

b) celočíselne vydeliť cenu predmetov v závislosti na  $\epsilon$ .

Nájst'  $C_{max}$  a vypočítať  $K = \frac{\epsilon \cdot C_{max}}{n}$ .

Prepočítať cenu každého predmetu ako  $C_i = \text{floor}(\frac{C_i}{K})$ . Zložitosť bude

$O(n^2 \cdot \text{floor}(\frac{n}{\epsilon}))$  \*

\* prevzaté z

<https://math.mit.edu/~goemans/18434S06/knapsack-katherine.pdf>


# Srovnání výpočetních časů metody větví a hranic, dynamického programování a heuristiky

Metódy *B&B* a *dekompozícia podľa ceny* prinášajú optimálne riešenie narozdiel od greedy heuristik.


Metóda *B&B* je výpočetne náročná a preto som ju testoval na sadách s počtom predmetov pod 25 predmetov. Na výpočtovom čase v sadách s {4, 10, 15, 20} predmetmi je viditeľná dominancia výpočetného času metódy *dekompozícia podľa ceny*. Pre obe metódy trvajú výpočty sekundy až stovky sekúnd, čo sa nedá vizuálne porovnávať s greedy heuristikami, ktoré majú výpočet v stotínach sekúnd.

## ZKC

Set of 500 instances of ZKC dataset using B&B

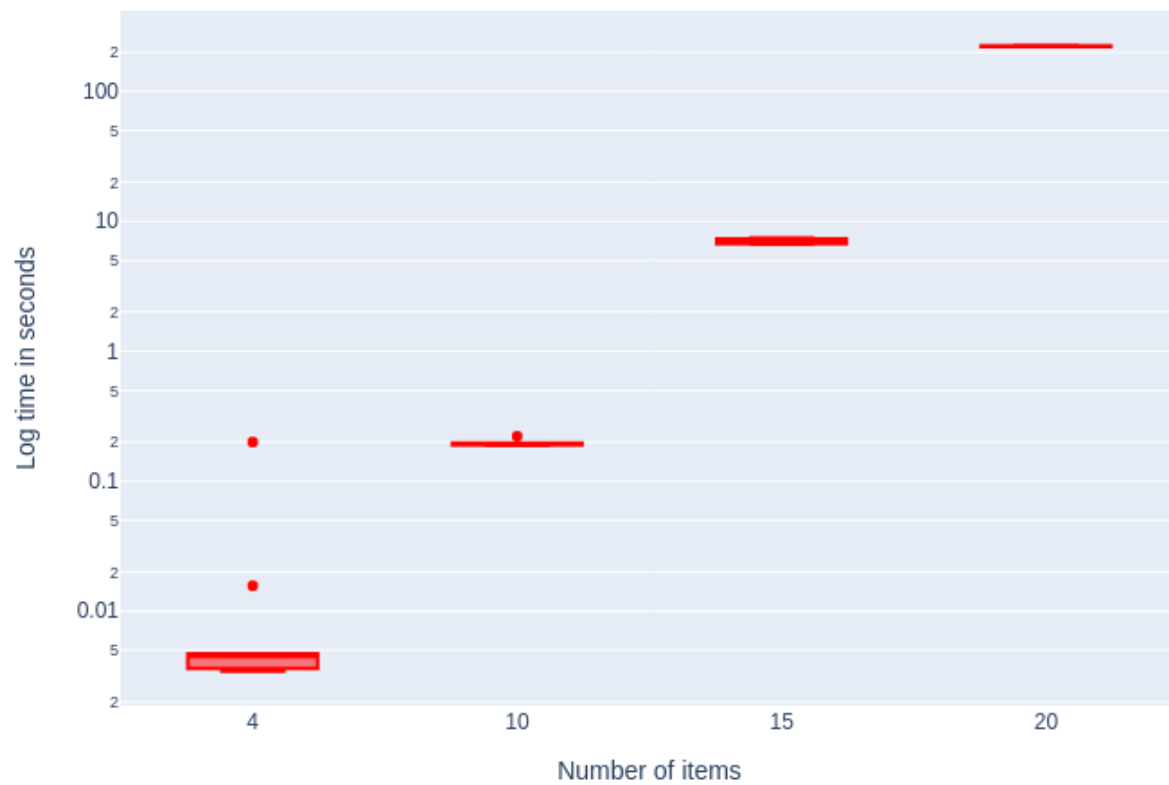


Set of 500 instances of ZKC dataset using price decomposition




## Logarithmic time scale

Set of 500 instances of ZKC dataset using B&B




Set of 500 instances of ZKC dataset using price decomposition




## NK

Set of 500 instances of NK dataset using B&B




Set of 500 instances of NK dataset using price decomposition






*Logarithmic time scale*

Set of 500 instances of NK dataset using B&amp;B




Set of 500 instances of NK dataset using price decomposition



Porovnanie datasetov NK a ZKC na B&B a price decomposition:  
ZKC bol výpočetne(časovo) oveľa náročnejší.

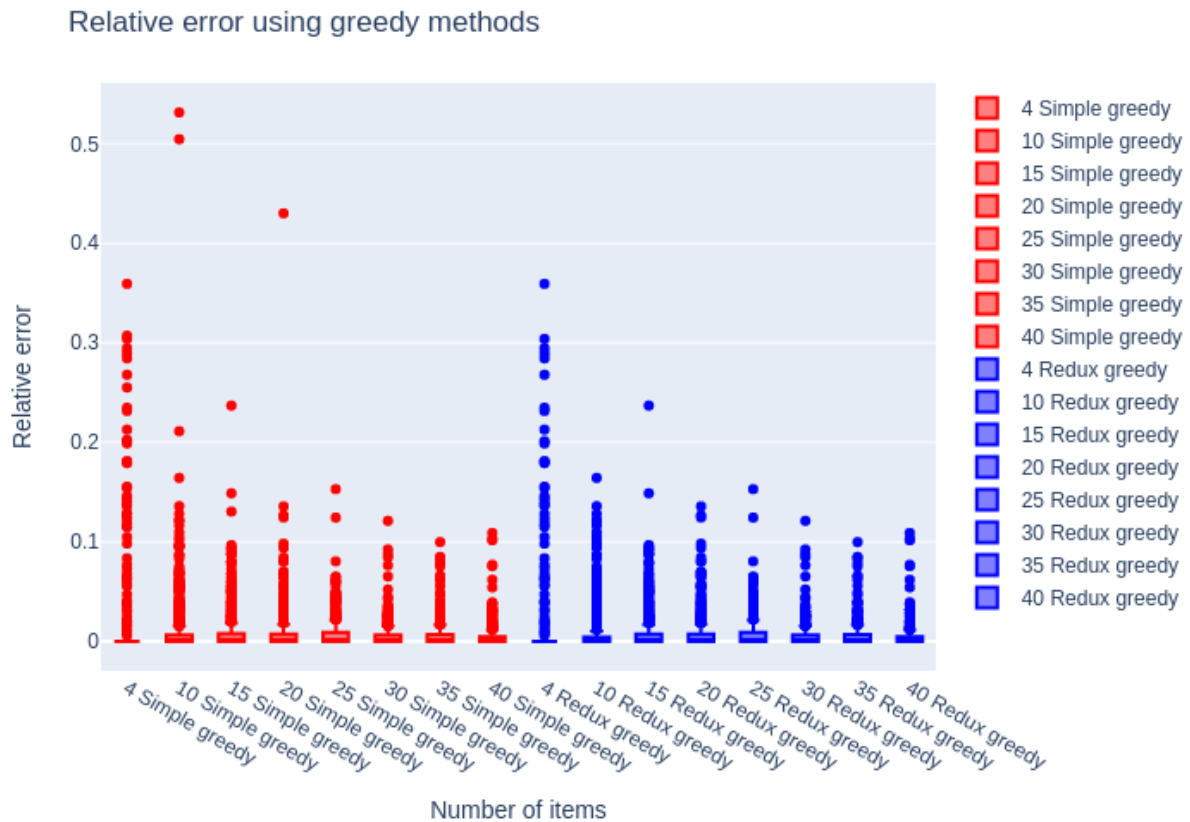
Greedy heuristiky nemusia prinášať optimálne riešenie a ich výpočet je veľmi rýchly.  
Na nižšie je vidno porovnanie výpočtového času bežnej greedy heuristiky a redukovanej greedy heuristiky na sadách ZKC a NK. Výpočtovo sú obe datasety podobne náročné, je to dané zložitou greedy heuristikou, ktorá zoradí predmety podľa pomeru cena/váha (zložitost' podľa radiaceho algoritmu,  $n \cdot \log n$ ) a postupne v lineárnom čase nájde riešenie.

Comparison of greedy and redux heuristics, set repeated 1000 times

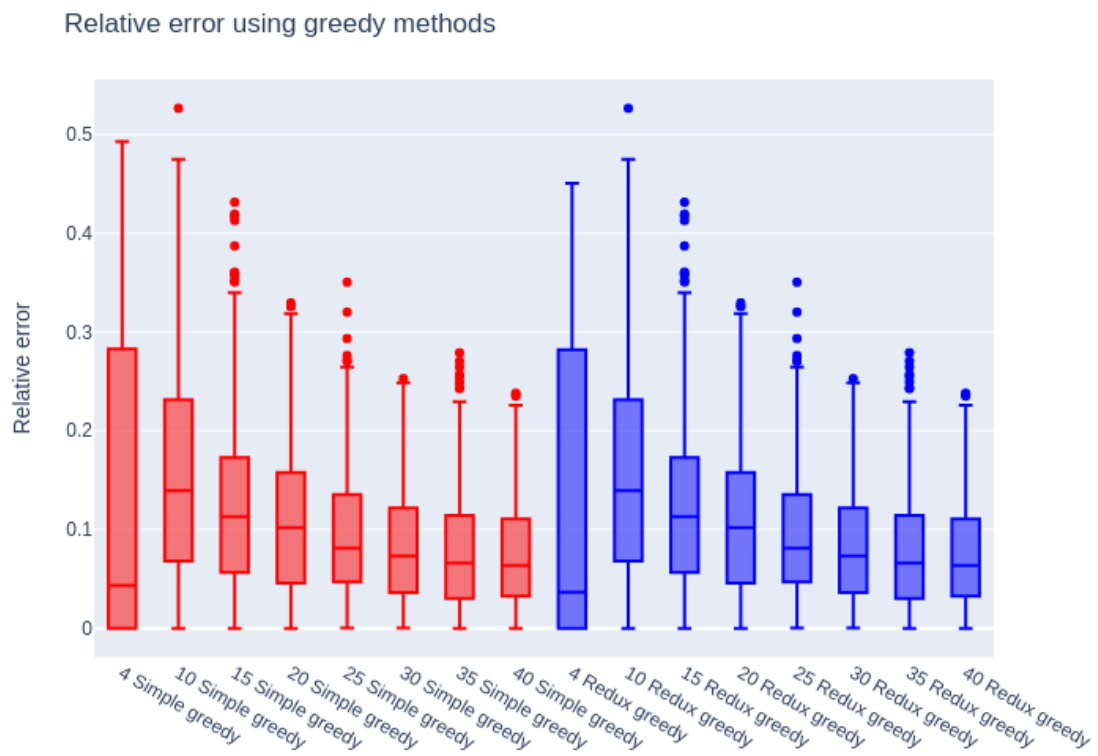


## Porovnání relativních chyb (průměrných a maximálních) obou heuristik.

Na grafe nižšie vidno rozdiel v priemerných relatívnych chybách jednoduchej a redukovanej greedy heuristiky. Jednoduchá greedy heuristika mala vyššiu priemernú aj maximálnu chybu v sade NK.

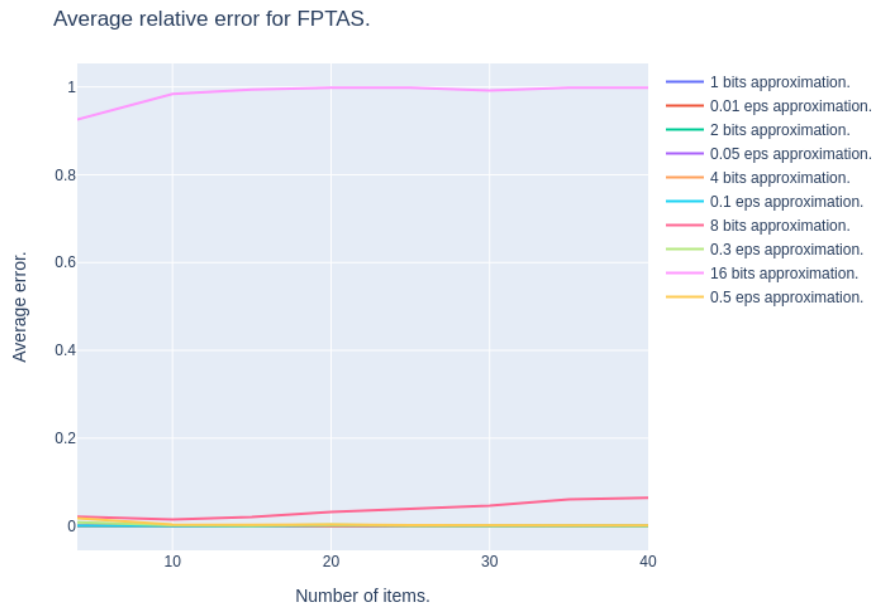


Pre sadu ZKC sú grafy porovnateľné, nie je vidno žiadny rozdiel medzi chybovosťou jednoduchšej a redukovanej heuristiky.

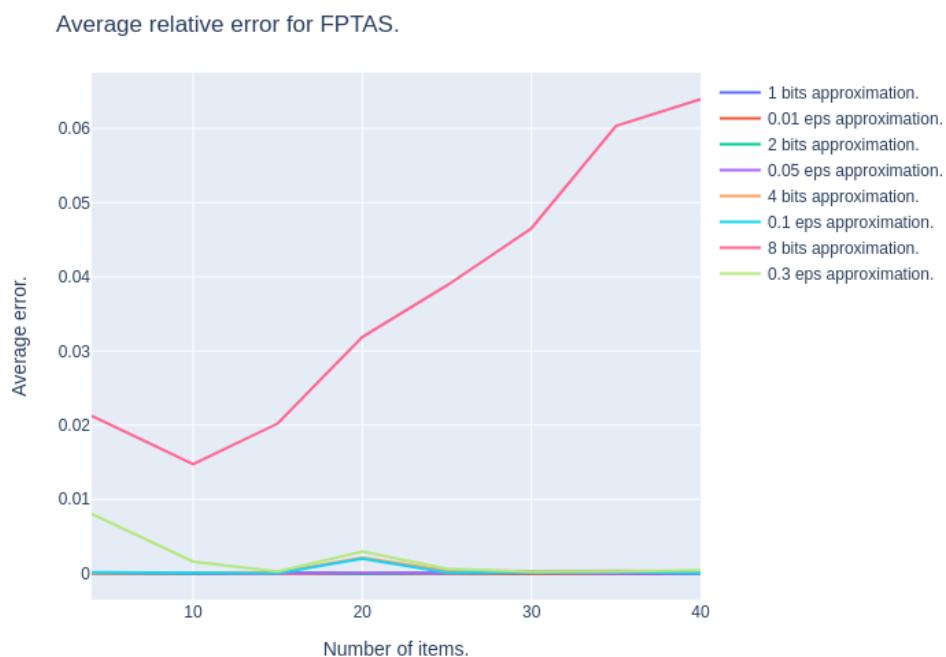


# FPTAS: závislost chyby a výpočetního času algoritmu na zvolené přesnosti zobrazení

Na obrázku nižšie sú grafy priemerných relatívnych chýb pre FPTAS aproximácie pomocou bitov aj požadovanej presnosti. Je vidno, že pri zanedbaní posledných 16 bitov je chyba príliš veľká, preto už nebudem zobrazovať tento priebeh. Chybu som počítal na datasete ZKC.

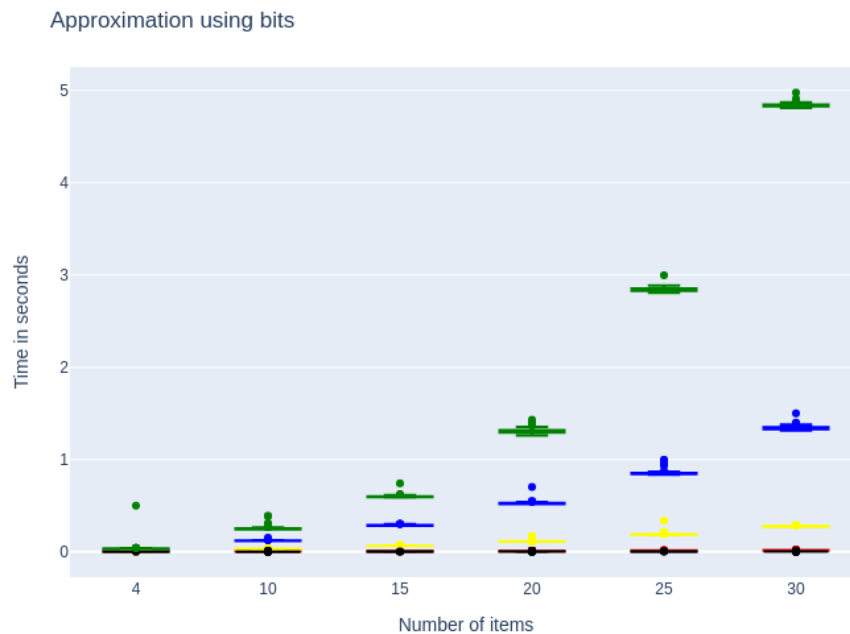


Pre aproximácie pomocou zanedbania {1, 2, 4, 8} bitov a požadovanú presnosť {0.01, 0.05, 0.1, 0.3} vidíme, že priemerná chyba je veľmi nízka.

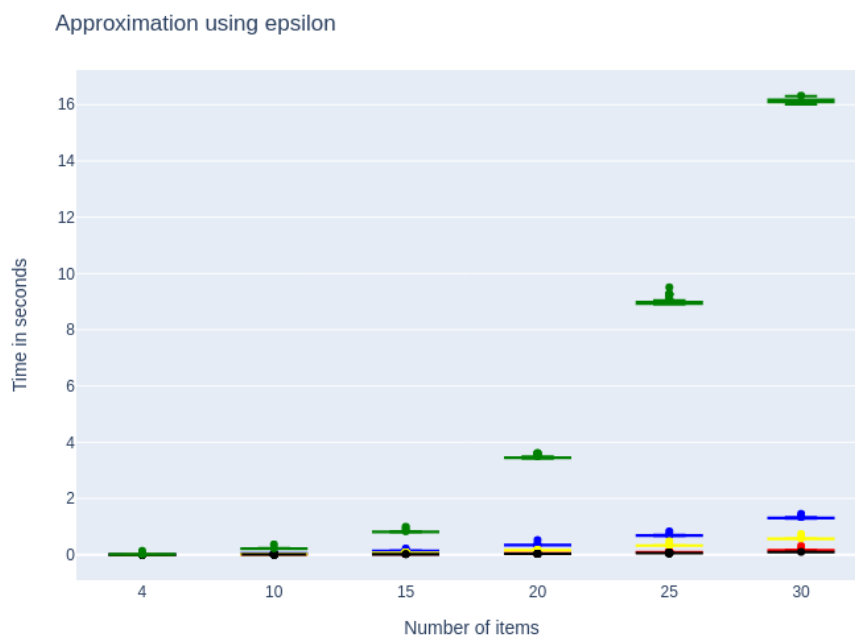


## Závislosť chyby a výpočtového času:

Súvisí to aj s výpočtovou náročnosťou modelu - na grafe vidno, že so stúpajúcou presnosťou rastie aj výpočetný čas.



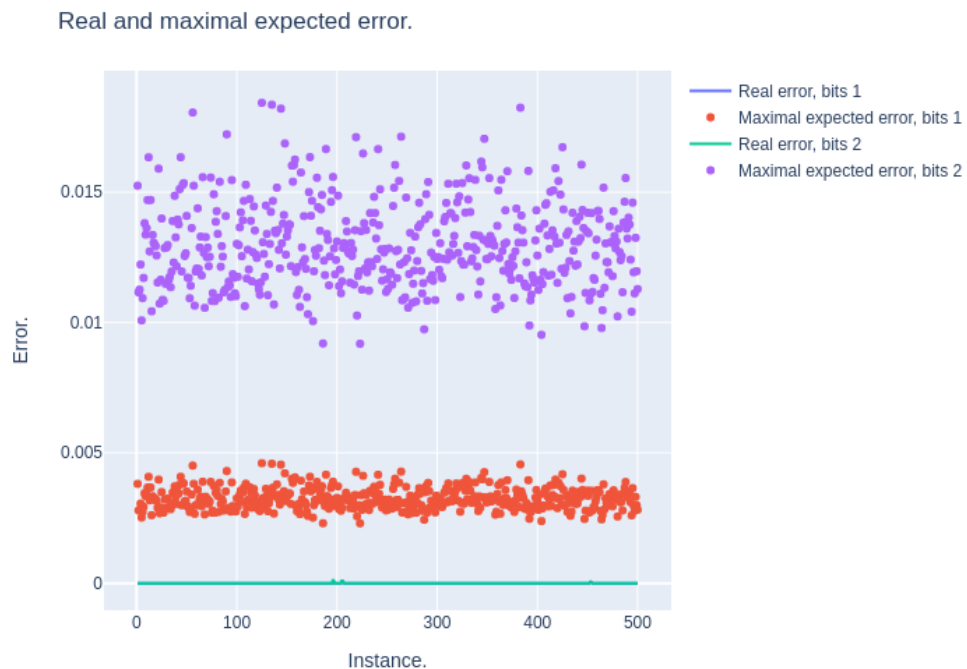
Počet bitov: zelená - 1 bit, modrá 2 bity, žltá 4 bity, červená 8 bitov, čierna 16 bitov



Epsilon: zelená - 0.01, modrá 0.05, žltá 0.1, červená 0.3, čierna 0.5

## Porovnanie maximálnej chyby s teoretickou očakávanou chybou:

Na grafe nižšie je vidno skutočnú nameranú chybu (čiara) porovnanú s maximálnou predpokladanou chybou (body). Pre obe hodnoty aproximácie pomocou {1, 2} bitov je skutočná chyba vždy nižšia ako maximálna predpokladaná.



Rovnako aj pre aproximáciu priamo cez maximálnu povolenú chybu.



# Zhodnocení naměřených výsledků

## 1. Odpovídají obě závislosti (kvality a času) předpokladům?

---

Experimenty ukazují, že při snižování požadované přesnosti (kvality) je snižována aj výpočtová náročnost a čas běhu. Ukázalo se, že skutečná chyba je často ovela nižší ako maximálna očakávaná chyba.

## 2. Je některá heuristická metoda systematicky lepší (tzv. dominance) v některém kritériu?

---

Jednoduchá greedy heuristika má podľa experimentov trend zlepšovať svoju presnosť pri zvyšovaní počtu predmetov. Môže to byť spôsobené tým, že väčší počet predmetov znižuje pravdepodobnosť vybrať nevhodný predmet na základe pomeru cena/váha. Pri redukovanej heuristike je vidno, že má často vysokú chybovosť ale v niektorých prípadoch ako to je vidno v grafe má lepšie výsledky ako jednoduchá heuristika. Výpočtová náročnosť oboch heuristik je porovnateľná.

## 3. Jaká je závislost maximální chyby ( $\epsilon$ ) a času FPTAS algoritmu na zvolené přesnosti? Odpovídá předpokladům?

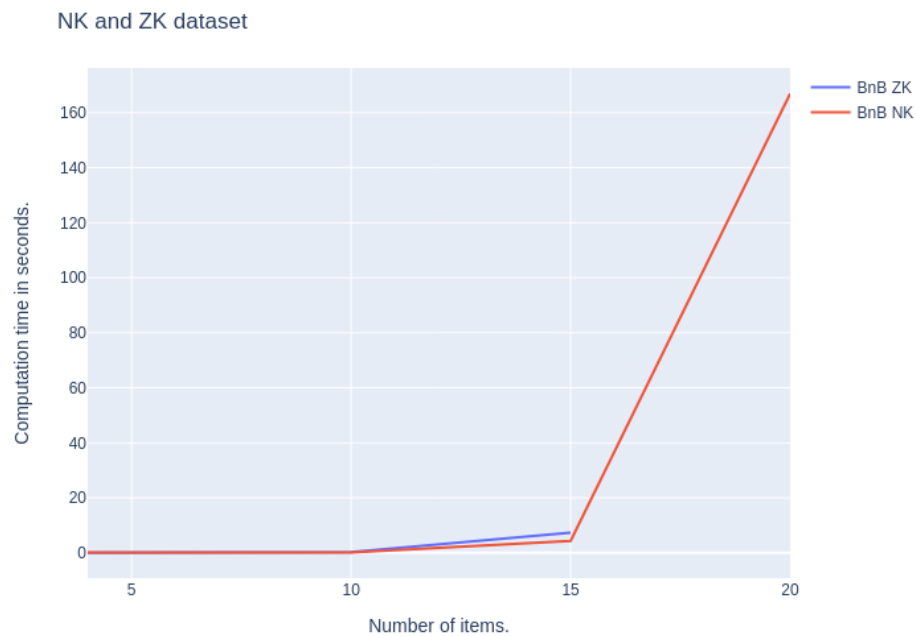

---

Čas běhu algoritmu je polynomiálně závislý od maximální požadované chyby ako je to vidno na grafoch. Odpovedá predpokladom  $O(n^2 \cdot \text{floor}(\frac{n}{\epsilon}))$ , kde je polynomiálna závislosť na  $1/\epsilon$  aj na  $n$ .




#### 4. Jak se liší obtížnosť jednotlivých sad z hlediska jednotlivých metod?

Sada ZK je výpočtovo zložitejšia ale napriek tomu porovnateľná ku sade NK. Porovnanie chyby medzi sadami som nevykonával.



NK and ZK dataset



NK and ZK dataset

